

Команда 39 — Отчёт о работе над задачей детекции дипфейков

Обзор проекта

Перед командой стояла задача бинарной классификации изображений: отличить реальные фотографии лиц (датасет Flickr) от лиц, сгенерированных с помощью StyleGAN. Датасет содержал 50 000 изображений для обучения и 10 000 для тестирования, с размером 256×256 пикселей. Ключевая особенность — дисбаланс классов и наличие искусственных артефактов в данных. Целевой метрикой служил **F1-score** с акцентом на максимизацию Recall (минимизацию ошибки второго рода).

Команда прошла полный путь от базовых одномоделных решений до продвинутого двухфазного стекинга из 10 нейросетей — каждый шаг давал новое понимание задачи и улучшал итоговый результат.

Этапы работы и история моделей

1. RegNet — точка отсчёта

Первая реализованная модель построена на **RegNet-подобной архитектуре** с bottleneck-блоками, grouped convolution и блоками Squeeze-and-Excitation. Это классическое, хорошо изученное решение позволило быстро получить первый стабильный результат и выстроить базовый пайплайн обучения.

Ключевые решения:

- 4 последовательных stage с нарастающей шириной каналов (232 → 696 → 1392 → 3712)
- CrossEntropyLoss с весами классов и label smoothing
- AdamW + OneCycleLR планировщик
- Аугментации: RandomResizedCrop, HorizontalFlip, ShiftScaleRotate, GaussNoise, Sharpen
- Test-Time Augmentation (TTA): усреднение предсказаний на оригинале и горизонтально отражённом изображении

RegNet доказал работоспособность базового подхода и стал эталоном для сравнения дальнейших архитектур.

2. RGB_FFT — первый шаг в частотную область

Ключевое наблюдение команды: StyleGAN оставляет характерные **следы в частотном пространстве**, которые невидимы человеческому глазу, но хорошо выделяются в амплитудном спектре Фурье. Это послужило мотивацией для создания двухпоточной архитектуры.

Архитектура:



Первая ветка обрабатывала стандартные RGB-каналы, вторая — логарифмически нормализованный амплитудный спектр FFT. Обучаемые скалярные коэффициенты α и β позволяли модели самостоятельно находить баланс между пространственными и частотными признаками. Внедрены модули внимания **CBAM** (Channel + Spatial Attention), Focal Loss для работы со сложными примерами, а также TTA и автоматический подбор порога F1.

3. ConvNeXt — современная сверточная архитектура

Параллельно была реализована модель на основе архитектуры **ConvNeXt-Tiny** — одного из самых современных на тот момент представителей класса «чистых» CNN, вдохновлённых Vision Transformer’ами.

Архитектура:

- Patchify Stem: Conv2d с ядром 4×4 и шагом 4
- 4 stage с ConvNeXt блоками (глубина 3-3-9-3, ширина 96-192-384-768)
- LayerNorm + Global Average Pooling
- Голова: Linear(768→256) → GELU → Dropout → Linear(256→1)

ConvNeXt-блоки отличаются от классических ResBlocks использованием depthwise convolution с большим ядром (7×7), инвертированного bottleneck, GELU-активаций и LayerNorm вместо BatchNorm, что делает их значительно устойчивее к переобучению.

4. RGB_FFT_LAP — тройной поток с оператором Лапласа

Развитие идеи многопоточных детекторов: к RGB и FFT потокам добавился третий — **лапласиан изображения**, улавливающий текстурные артефакты и резкие границы на уровне градиентов.

Архитектура:



Ветка лапласиана использовала фиксированное ядро оператора Лапласа как необучаемый фильтр, что позволило захватить тонкие неоднородности в текстуре кожи — паразитный признак многих генеративных моделей. Три обучаемых веса α , β , γ динамически балансировали вклад каждого потока.

5. EfficientNetB3 — ручная реализация эффективной архитектуры

Следующим шагом стала полная **ручная реализация EfficientNet-B3** с нуля, без использования предобученных весов из torchvision.

Ключевые элементы:

- MBConv блоки с depthwise convolution 3×3 и 5×5
- Squeeze-and-Excitation в каждом блоке
- Stochastic Depth для регуляризации (вероятность дропа до 0.2)
- 7 stage с конфигурацией (width_mult=1.2, depth_mult=1.4)
- Финальная голова: Conv(384→1536) → Pool → Dropout(0.3) → Linear(1536→1)

Расширенные аугментации через Albumentations: ImageCompression, Downscale, GaussianBlur, MedianBlur, ISONoise, MultiplicativeNoise, CoarseDropout. Обучение с OneCycleLR и pos_weight для компенсации дисбаланса классов.

6. DualStreamNetV2 — двойные ResBlocks, Cross-Stream Fusion и SWA

Значительное усложнение двухпоточной парадигмы. Эта архитектура создавалась специально под **NVIDIA A100** с оптимизациями под bfloat16.

Ключевые инновации:

- **Double ResBlocks** — удвоенные остаточные блоки в каждом потоке для большей глубины
- **Cross-Stream Fusion** на двух уровнях — потоки обмениваются признаками через обучаемые гейтирующие коэффициенты
- **CBAM** в каждой ветке (канальное + пространственное внимание)
- **GPU-батчевое FFT** — частотный спектр вычислялся прямо на GPU пакетами, что критически ускорило обучение
- **Stochastic Weight Averaging (SWA)** — финальные веса усреднялись по последним эпохам, улучшая обобщение
- **CutMix** с пересчётом FFT прямо в GPU-буфере после каждого смешивания патчей

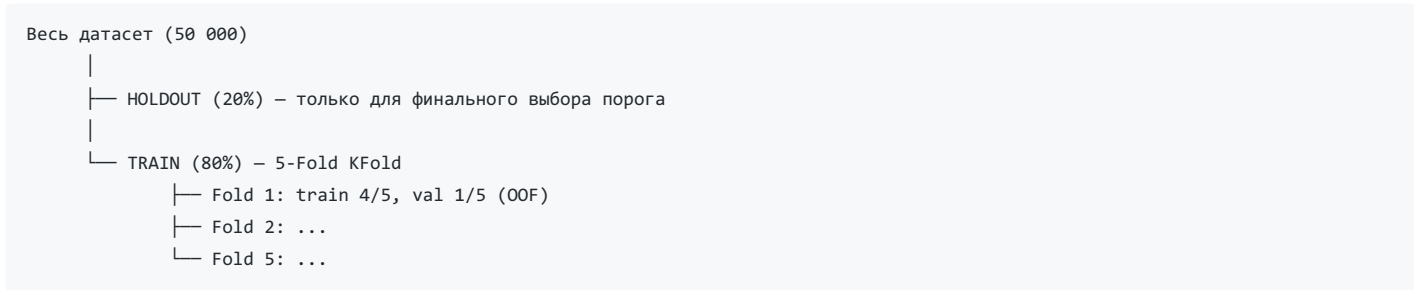


7. HFDualCNN – K-Fold + SBI аугментация

Архитектура HFDualCNN привнесла две важных методологических идеи: **K-Fold кросс-валидацию** и **Self-Blended Images (SBI)** аугментацию.

SBI – мощная техника синтетической аугментации: берётся реальное изображение, вырезается патч, к нему применяются артефакты ресайза/размытия/сдвига яркости, и затем патч вклеивается обратно через сглаженную эллиптическую маску. Это имитирует граничные артефакты генеративных моделей, заставляя сеть учиться искать тонкие несоответствия на стыках пикселей.

Схема без data leakage:



Дополнительно: Global Attention Layer для взвешенной агрегации признаков из двух веток, EMA-усреднение весов модели (decay=0.999), Focal Loss (gamma=2.0) для фокуса на сложных примерах, планировщик вероятности SBI от 0.15 до 0.45 в ходе обучения.

8. RobustSRMTopKMILNetV2 – локальный анализ патчей через SRM и MIL

Нетривиальная архитектура, совмещающая **глобальный анализ** всего изображения и **локальный анализ подозрительных патчей** через SRM-фильтры (Spatial Rich Model) и Multiple Instance Learning.

Две ветки:

Глобальная RGB ветка – анализирует изображение целиком через SeparableResidualBlocks.

Локальная SRM-патч ветка:

1. Применяет фиксированные SRM-фильтры (высокочастотные шумовые фильтры из стеганографии) с порогом HardTanh
2. Нарезает изображение на патчи (96×96): 9 случайных при обучении, сетка 3×3 при инференсе
3. Кодирует RGB-патчи и SRM-патчи отдельными энкодерами
4. Объединяет через Gated Patch Fusion
5. **Top-K MIL pooling**: выбирает только 4 наиболее подозрительных патча из 9

```
Input [B, 3, 256, 256]
├── Global RGB branch → global_feature [B, 256]
├──
└── SRM filters → Patches → Encoders → Gated Fusion
    → Top-4 MIL → local_feature [B, 256]

global + local → LayerNorm → Concat
    → Linear(512→128) → SiLU → Dropout → Linear(128→1)
```

Auxiliary losses от глобальной и локальной веток стабилизировали обучение и направляли градиенты в обе ветки.

9. IR-CFA-CCNet — форензик-анализ с CFA-признаками

Самая специализированная архитектура в арсенале команды, основанная на методах **цифровой форензики изображений**. Использует CFA (Color Filter Array) паттерны — метаданные о сенсоре камеры — которые в реальных фотографиях образуют характерные регулярные структуры, отсутствующие в GAN-изображениях.

Ключевые особенности:

- GroupNorm вместо BatchNorm (устойчив к малым батчам и артефактам нормализации)
- **CFA самообучение:** 3 эпохи предобучения CFA-модуля только на реальных изображениях (freeze_cfa_after_pretrain=True)
- **ImpulseGate** — детектор импульсного шума
- **ForensicBlock** — специализированные блоки для извлечения форензик-признаков
- **SignedGeM pooling** — обобщённый пулинг со знаком, сохраняющий информацию о знаке аномалий
- Входные изображения намеренно **без ImageNet нормализации** — физический масштаб RGB [0,1] критичен для работы CFA-детектора
- `logit_tanh_scale = 12.0` — ограничение диапазона логитов через tanh

Строгий контроль anti-leakage: validation split IR-CFA строился из тех же ID, что и core ensemble, исключая возможность пересечения.

10. EfficientNetV5 (super_level_up) — OOF-обучение и финальный файнтюн

Последняя одиночная модель, созданная с осознанием, что ансамбль достиг зоны насыщения. Идея: взять лучшее ядро ансамбля (EfficientNetB3) и сделать честную оценку через **Out-of-Fold схему**, а затем дообучить на полном датасете.

Архитектура EfficientNetV5:

- Три типа блоков: ConvBnAct, EdgeResidual (fused-MBConv), InvertedResidual
- Входной размер 384×384 (вместо 256×256)
- 6 stage с нарастающей глубиной (2-4-4-6-9-15 блоков)
- Conv Head: 256→1280 → Pool → BN → Dropout → Linear(1280→512) → GELU → BN → Dropout → Linear(512→1)

Нова в пайплайне обучения:

- **5-fold OOF:** каждое изображение побывало и в train, и в val
- **Focal Loss** (alpha=0.75, gamma=2.0) + label_smoothing=0.03
- **EMA** (Exponential Moving Average) весов
- **Hard negative mining** для фокуса на сложных примерах
- **MixUp + CutMix** как дополнительные техники смешивания данных
- **Salt-and-pepper overlay** (вероятность 0.30) — имитация артефактов датасета
- **SBI-аугментация** с нарастающей вероятностью (0.02 → 0.15)
- Gradient accumulation (4 шага) для эффективного батча
- `channels_last` memory format для ускорения на GPU
- После OOF — дообучение на **полном** train датасете на лучшем fold

ТТА из 8 вариантов при инференсе: оригинал, HFlip, VFlip, HFlip+VFlip, масштабирование ×1.10, масштабирование ×1.15 + HFlip, поворот +5°, поворот −5°.

Ансамблирование

После обучения отдельных моделей команда исследовала различные комбинации ансамблей. Для каждой модели были сохранены **логиты и вероятности** на validation и test выборках в формате Parquet-файлов.

Был проведён корреляционный анализ логитов: модели с низкой попарной корреляцией вносят наибольший взаимодополняющий вклад в ансамбль. На основе этого анализа отбирались наиболее перспективные комбинации.

Финальный стекинг (Stacking Ensemble v2)

Самый сложный и тщательно продуманный этап — двухфазный поиск оптимального мета-классификатора поверх 10 базовых моделей.

Идея: вместо простого усреднения логитов обучить отдельную модель, которая определяет, **какому из предсказаний доверять** в зависимости от конкретного примера.

Входные данные: OOF-логиты 10 нейросетей как признаки (фичи) мета-модели.

Фаза 1 — перебор всех 1023 комбинаций

Три быстрых MLP-варианта, оптимизированных под `torch.vmap` (без BatchNorm и Dropout):

Модель	Идея
FastMetaMLP	<code>output = skip(x) + $\sigma(\alpha) \cdot \text{branch}(x)$</code> — начинает как LogReg, постепенно включает нелинейность
AttentionMLP	<code>w = softmax($W_s x$)</code> , взвешенная сумма — динамически доверяет разным моделям
GatedResidualMLP	GLU-style gating: <code>sigmoid($W_g \cdot x$) $\odot$ tanh($W_h \cdot x$)</code> — что пропустить, что заблокировать

Фаза 2 — топ-50 комбинаций, тяжёлые алгоритмы

Для 50 лучших комбинаций (по OOF F1 из Фазы 1) запускались:

- LightGBM (~4 сек на комбинацию)
- Random Forest
- Gradient Boosting

Итоговое предсказание — взвешенное объединение результатов всех шести мета-моделей. Жёсткий контроль data leakage: мета-модель обучалась только на OOF-предсказаниях, никогда не видя test данные напрямую.

Общие технические решения

На протяжении всей работы команда применяла ряд сквозных техник:

Работа с дисбалансом классов: WeightedRandomSampler, pos_weight в BCEWithLogitsLoss, Focal Loss.

Оптимизация обучения: AdamW с cosine/OneCycle планировщиками, gradient clipping, AMP (mixed precision), ранняя остановка по F1.

Надёжность предсказаний: Test-Time Augmentation во всех моделях, динамический поиск оптимального порога классификации на validation выборке.

Контроль воспроизводимости: фиксированный seed=42 во всех экспериментах.

Хранение промежуточных результатов: логиты и вероятности каждой модели сохранялись в Parquet для последующего ансамблирования.

Итог

Команда 39 прошла путь от классического RegNet до форензик-моделей с CFA-признаками, реализовав более 10 уникальных архитектур. Параллельно развивалась методология: от простого train/val split — к K-Fold и OOF, от CrossEntropy — к Focal Loss и вспомогательным лоссам, от одиночных предсказаний — к двухфазному стекингу из 10 моделей с 6 мета-алгоритмами.

Итоговая система объединяет лучшее из каждого направления исследований: пространственный анализ, частотный анализ (FFT), текстурный анализ (Лаплас, SRM), локальный патч-анализ (MIL), форензик-признаки (CFA) — и метаклассификатор, научившийся взвешивать доверие к каждому из этих подходов на уровне конкретного примера.